

AI Project

3. 다층 퍼셉트론 모델

GNB 김도훈

Index


1. 2주차 교육 내용 복습
2. 퍼셉트론과 활성화 함수
3. 다층 퍼셉트론 모델
4. 순전파와 역전파
5. Lab 3 : Multilayer Perceptron

복습: Train / Test split


| Data | |
|-------|------|
| Train | Test |

- Train set : 최적해 θ^* 를 구하기 위한 데이터
- Test set : 새로운 데이터에 대한 θ^* 의 적합도를 평가하기 위한 데이터
- Train error와 Test error를 비교하여 학습이 잘 되었는지 평가하기 위함
- 학습에 사용하지 않은 데이터로 모델의 성능을 평가

복습: 모델 복잡도와 문제 복잡도

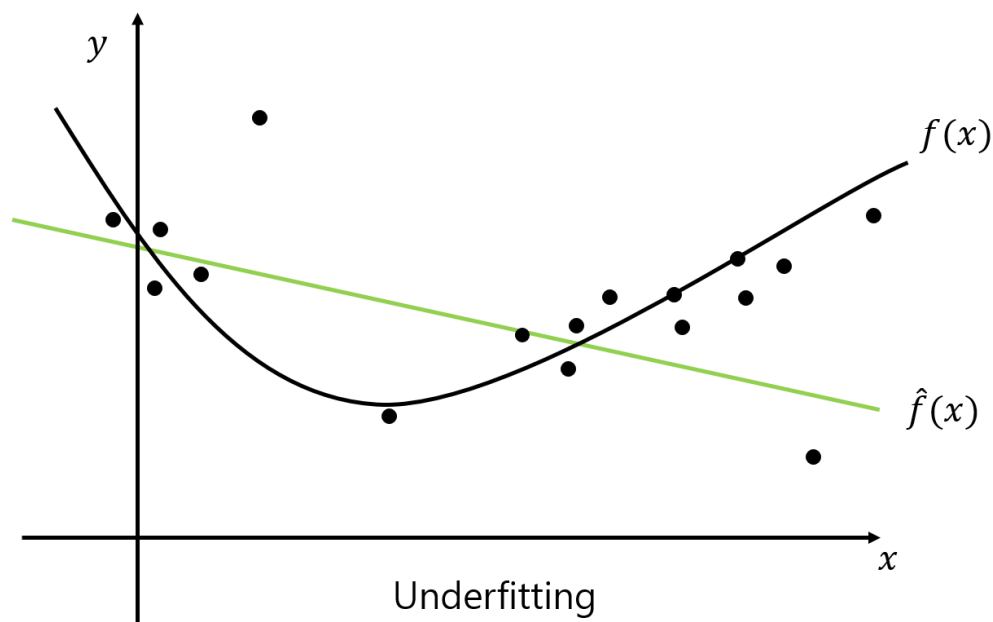


$Var(\hat{\theta})$: test error
 $(Bias(\hat{\theta}))^2$: train error




문제의 복잡도에 맞는 복잡도를 가진 모델을 선택

복습: 과소적합, 과적합 문제



model complexity \downarrow
 $Var(\hat{\theta}) \downarrow$
 $(Bias(\hat{\theta}))^2 \uparrow$



model complexity \uparrow
 $Var(\hat{\theta}) \uparrow$
 $(Bias(\hat{\theta}))^2 \downarrow$

복습: 정규화

- θ 의 크기를 제한 \Rightarrow 과적합 완화


$$\theta^* = \operatorname{argmin}_{\theta} E(\theta)$$

$$s. t. \quad \|\bar{\theta}\|_p^p \leq c^p$$


Lagrangian method

$$\theta^* = \operatorname{argmin}_{\theta} \left(E(\theta) + \lambda \left(\|\bar{\theta}\|_p^p - c^p \right) \right)$$

$$\theta^* = \operatorname{argmin}_{\theta} \left(E(\theta) + \lambda \|\bar{\theta}\|_p^p \right)$$



Lasso : p=1



Ridge : p=2

복습: Ridge 정규화

1. 경사 하강법

$$\theta_n \leftarrow \theta_n - \alpha \left(\sum_{i=1}^I \left(\theta^T x^{(i)} - y^{(i)} \right) x_n^{(i)} - \lambda \theta_n \right)$$

데이터로부터 학습한 정보를 덜 신뢰한다!

2. Closed-form solution

$$\theta^* = \left(x^T x + \lambda \begin{bmatrix} 0 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} \right)^{-1} x^T y$$

$shape : [N + 1, N + 1]$

- 행렬의 크기

$\theta : [N + 1, 1]$

$x : [I, N + 1]$


$y : [I, 1]$

인공 신경망 (Artificial Neural Network)


- 인공 신경망(ANN)은...
 - 인간의 신경 조직을 수학적으로 모델링하여
 - 컴퓨터가 인간처럼 기억·학습·판단할 수 있도록 구현한 것
- 인공 신경망의 종류
 - Feedforward neural network
 - 다층 퍼셉트론(MLP)은 FFNN에 해당한다.
 - Feedback neural network
 - 순환 신경망(Recurrent neural network) = FBNN

퍼셉트론 (Perceptron)

- 뉴런의 기능을 수학적으로 모델링한 것




뉴런의 구조



퍼셉트론의 구조

퍼셉트론 (Perceptron)

- 퍼셉트론의 구조




$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$$

$$v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_N \end{bmatrix}$$

$$z = x \cdot v = x_1 v_1 + \dots + x_N v_N$$


$$\hat{y} = h(z) = h_v(x)$$

활성화 함수 (Activation function)



- 뉴런의 동작
 - 뉴런의 휴지 전위는 -70mV
 - 역치 전위는 -55mV
 - 자극이 오면 막이 탈분극한다.
 - 충분히 탈분극하여 역치 전위에 도달하면 활동 전위가 일어난다.
- 자극이 기준값보다 크면 증폭!
- 자극이 기준값보다 작으면 무시!

활성화 함수 (Activation function)



1. Sigmoid (=Logistic function)

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

2. Hyperbolic tangent


$$\tanh(z) = \frac{\sinh z}{\cosh z} = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

이외에도 매우 다양한 활성화 함수가 존재한다.


데이터와 모델의 특성에 맞는 활성화 함수를 선택해서 사용한다.

다층 퍼셉트론 (Multilayer Perceptron)

- 2개의 층을 가진 MLP 모델



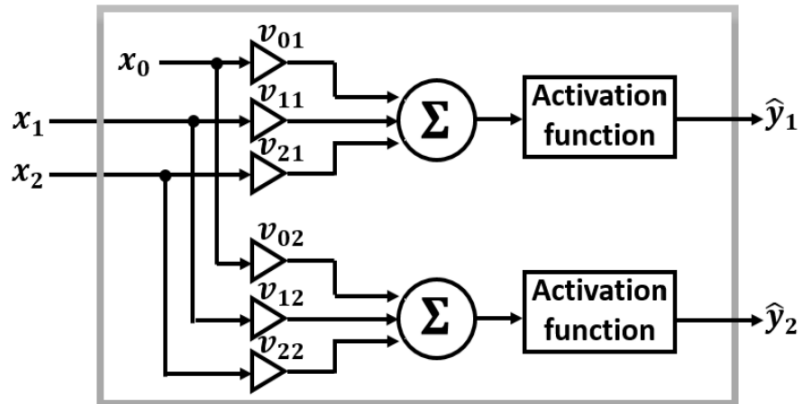

모델의 Layer 구조를 단순히 나타낸 표현



실제 값의 연산과정을 확인할 수 있는 표현

다층 퍼셉트론 (Multilayer Perceptron)

- 2개의 층을 가진 MLP 모델



$$x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} \quad v = \begin{bmatrix} v_1 & v_2 \end{bmatrix} = \begin{bmatrix} v_{01} & v_{02} \\ v_{11} & v_{12} \\ v_{21} & v_{22} \end{bmatrix}$$


$$v_1 = \begin{bmatrix} v_{01} \\ v_{11} \\ v_{21} \end{bmatrix} \quad v_2 = \begin{bmatrix} v_{02} \\ v_{12} \\ v_{22} \end{bmatrix}$$

$$\hat{y}_1 = x \cdot v_1 = x^T v_1 = x_0 v_{01} + x_1 v_{11} + x_2 v_{21}$$

$$\hat{y}_2 = x \cdot v_2 = x^T v_2 = x_0 v_{02} + x_1 v_{12} + x_2 v_{22}$$

다층 퍼셉트론 (Multilayer Perceptron)

- 3개의 층을 가진 MLP 모델



x_0, f_0 : bias (=intercept)

N : 입력 데이터의 차원

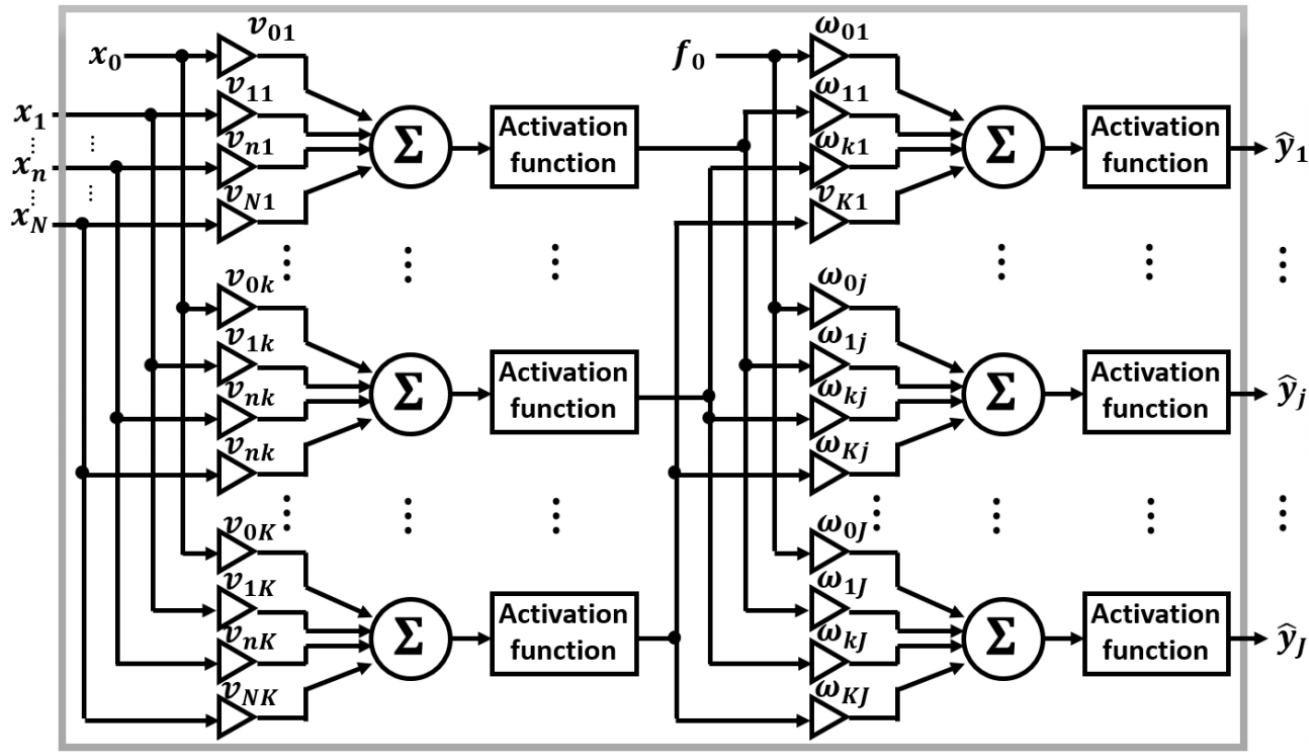
I : 입력 데이터의 개수

J : 출력 데이터의 차원

K : 은닉층의 뉴런 개수

다층 퍼셉트론 (Multilayer Perceptron)

- 3개의 층을 가진 MLP 모델



$$v = \begin{bmatrix} v_{01} & v_{02} & \cdots & v_{0K} \\ v_{11} & v_{12} & \cdots & v_{1K} \\ \vdots & \vdots & \ddots & \vdots \\ v_{N1} & v_{N2} & \cdots & v_{NK} \end{bmatrix}$$

$$W = \begin{bmatrix} w_{01} & w_{02} & \cdots & w_{0J} \\ w_{11} & w_{12} & \cdots & w_{1J} \\ \vdots & \vdots & \ddots & \vdots \\ w_{K1} & w_{K2} & \cdots & w_{KJ} \end{bmatrix}$$

다층 퍼셉트론 (Multilayer Perceptron)

- 오차 함수 : Sum of squared error

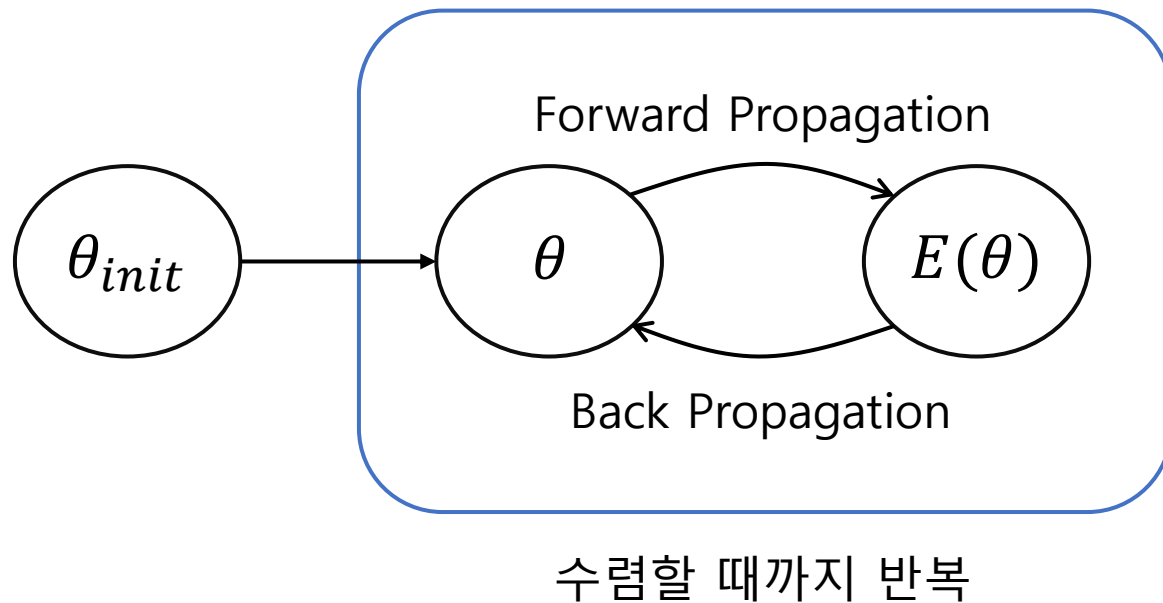
$$E(\theta) = \frac{1}{2} \sum_{i=1}^I \|\hat{y}^{(i)} - y^{(i)}\|_2^2 = \frac{1}{2} \sum_{i=1}^I \sum_{j=1}^J \left(\hat{y}_j^{(i)} - y_j^{(i)} \right)^2$$

- 문제 정의 : 비용 극소화 문제

$$\theta^* = \underset{\theta}{\operatorname{argmin}} E(\theta), \quad \theta = (v, w)$$

다층 퍼셉트론 (Multilayer Perceptron)

- 이 문제를 풀기 위한 방법



- 순전파
파라미터 θ 값으로 부터
오차 E 를 구하는 과정
- 역전파
오차 E 를 통해 파라미터
 θ 를 업데이트하는 과정

순전파 (Forward propagation)

Input data matrix

$$X = \begin{bmatrix} (x^{(1)})^T \\ \vdots \\ (x^{(I)})^T \end{bmatrix}, \quad \text{where } x^{(i)} \in \mathbb{R}^{N \times 1} \quad (1)$$

$I \times N$

Extended input data matrix

$$\bar{X} = [\mathcal{I} \quad X] = \begin{bmatrix} (\bar{x}^{(1)})^T \\ \vdots \\ (\bar{x}^{(I)})^T \end{bmatrix}, \quad \text{where } \mathcal{I} = [1, \dots, 1]^T \in \mathbb{R}^{I \times 1} \quad (2)$$

$I \times (N + 1)$

↑
intercept

$$\bar{\bar{X}} = \bar{X} \cdot v = \begin{bmatrix} (\bar{x}^{(1)})^T \cdot v \\ \vdots \\ (\bar{x}^{(I)})^T \cdot v \end{bmatrix} \quad (3)$$

$I \times K$

순전파 (Forward propagation)

Define

$$F = \underset{\text{sigmoid}}{\left(1 + \exp\left(-\overline{\overline{X}}\right)\right)^{-1}} = \begin{bmatrix} (f^{(1)})^T \\ \vdots \\ (f^{(I)})^T \end{bmatrix} \quad I \times K \quad (4)$$

where the operator $^{-1}$ represents the elementwise inversion.

$$\overline{F} = \underset{\substack{\uparrow \\ \text{intercept}}}{[\mathcal{I} \quad F]} = \begin{bmatrix} (\overline{f}^{(1)})^T \\ \vdots \\ (\overline{f}^{(I)})^T \end{bmatrix} \quad I \times (K + 1), \quad \text{where } \mathcal{I} = [1, \dots, 1]^T \in \mathbb{R}^{I \times 1} \quad (5)$$

$$\overline{\overline{F}} = \overline{F} \cdot \omega = \begin{bmatrix} (\overline{f}^{(1)})^T \cdot \omega \\ \vdots \\ (\overline{f}^{(I)})^T \cdot \omega \end{bmatrix} \quad I \times J \quad (6)$$

순전파 (Forward propagation)

Define

$$G = \underbrace{\left(1 + \exp\left(-\overline{\overline{F}}\right)\right)^{-1}}_{\text{sigmoid}} = \begin{bmatrix} (g^{(1)})^T \\ \vdots \\ (g^{(I)})^T \end{bmatrix}_{I \times J} \quad (7)$$

where $^{-1}$ represents once again the elementwise inversion.

Then, one can find the labels using the following algorithm:

Algorithm 1: find labels

```
1 Initialize label;  
2 for  $i = 1 : I$  do  
3    $\lfloor \text{label}(i) \leftarrow \arg \max_j G(i, j) - 1;$   
4 return label;
```

순전파 (Forward propagation)


Let us define the **sum of squared errors (SSE)** as

$$E = \frac{1}{2} \sum_{i=1}^I (\hat{y}^{(i)} - y^{(i)})^2 = \frac{1}{2} \sum_{i=1}^I \sum_{j=1}^J (\hat{y}_j^{(i)} - y_j^{(i)})^2 = \frac{1}{2} \sum_{i=1}^I \sum_{j=1}^J (g_j^{(i)} - y_j^{(i)})^2 \quad (8)$$

where $g_j^{(i)} = g(\bar{f}(\bar{x}^{(i)})) = g \circ \bar{f}(\bar{x}^{(i)})$.

- 순전파 요약

순전파는 파라미터 θ 값으로 부터 오차 E 를 구하는 과정이다.



역전파 (Back propagation)

- 배치 경사 하강법(BGD)를 통해서 역전파

The update rules are

$$\begin{aligned} v_{nk} &\leftarrow v_{nk} - \alpha_v \frac{\partial E}{\partial v_{nk}} \\ w_{kj} &\leftarrow w_{kj} - \alpha_w \frac{\partial E}{\partial w_{kj}} \end{aligned} \tag{9}$$

But, what are $\frac{\partial E}{\partial v_{nk}}$ and $\frac{\partial E}{\partial w_{kj}}$?

Let us compute first $\frac{\partial E}{\partial w_{kj}}$.

$$\frac{\partial E}{\partial w_{kj}} = \frac{\partial}{\partial w_{kj}} \left[\frac{1}{2} \sum_{i=1}^I \sum_{j'=1}^J \left(g_{j'}^{(i)} - y_{j'}^{(i)} \right)^2 \right] = \sum_{i=1}^I \frac{\partial}{\partial w_{kj}} \left[\frac{1}{2} \sum_{j'=1}^J \left(g_{j'}^{(i)} - y_{j'}^{(i)} \right)^2 \right] = \sum_{i=1}^I \left(g_j^{(i)} - y_j^{(i)} \right) \frac{\partial g_j^{(i)}}{\partial w_{kj}}$$

역전파 (Back propagation)

For simplicity, let us drop the notation $^{(i)}$ and compute $\frac{\partial g_j}{\partial w_{kj}}$.

$$\begin{aligned}\frac{\partial g_j}{\partial w_{kj}} &= \frac{\partial}{\partial w_{kj}} \left(\frac{1}{1 + e^{-(\bar{f})^T w_j}} \right) \\ &= \frac{-e^{-(\bar{f})^T w_j}}{\left(1 + e^{-(\bar{f})^T w_j}\right)^2} (-\bar{f}_k) \\ &= \frac{1}{1 + e^{-(\bar{f})^T w_j}} \left(1 - \frac{1}{1 + e^{-(\bar{f})^T w_j}} \right) \bar{f}_k \\ &= g_j(1 - g_j)\bar{f}_k\end{aligned}\tag{11}$$

역전파 (Back propagation)

Hence,

$$\frac{\partial E}{\partial w_{jk}} = \sum_{i=1}^I \left(g_j^{(i)} - y_j^{(i)} \right) \frac{\partial g_j}{\partial w_{kj}} g_j^{(i)} \left(1 - g_j^{(i)} \right) \bar{f}_k^{(i)} \quad (12)$$

$$w_{kj} \leftarrow w_{kj} - \alpha_1 \sum_{i=1}^I \left(g_j^{(i)} - y_j^{(i)} \right) g_j^{(i)} \left(1 - g_j^{(i)} \right) \bar{f}_k^{(i)} \quad (13)$$

where $k = \{0, 1, \dots, K\}$ and $j = \{1, 2, \dots, J\}$.

역전파 (Back propagation)

Now, let us compute $\frac{\partial E}{\partial v_{nk}}$.

$$\frac{\partial E}{\partial v_{nk}} = \frac{\partial}{\partial v_{nk}} \left[\frac{1}{2} \sum_{i=1}^I \sum_{j=1}^J \left(g_j^{(i)} - y_j^{(i)} \right)^2 \right] = \sum_{i=1}^I \sum_{j=1}^J \frac{\partial}{\partial v_{nk}} \left[\frac{1}{2} \left(g_j^{(i)} - y_j^{(i)} \right)^2 \right] \quad (14)$$

Then,

$$\frac{\partial}{\partial v_{nk}} \left[\frac{1}{2} \left(g_j^{(i)} - y_j^{(i)} \right)^2 \right] = \left(g_j^{(i)} - y_j^{(i)} \right) \frac{\partial g_j^{(i)}}{\partial v_{nk}} \quad (15)$$

For simplicity, let us drop the notation $^{(i)}$ and compute $\frac{\partial g_j}{\partial v_{nk}}$.

$$\frac{\partial g_j}{\partial v_{nk}} = \frac{\partial g_j}{\partial \bar{f}_k} \frac{\partial \bar{f}_k}{\partial v_{nk}} \quad (16)$$

역전파 (Back propagation)

On the other hand,

$$\begin{aligned}\frac{\partial g_j}{\partial \bar{f}_k} &= \frac{\partial}{\partial \bar{f}_k} \left(\frac{1}{1 + e^{-(\bar{f})^T w_j}} \right) \\ &= \frac{-e^{-(\bar{f})^T w_j}}{(1 + e^{-(\bar{f})^T w_j})^2} (-w_{kj}) \\ &= \frac{1}{1 + e^{-(\bar{f})^T w_j}} \left(1 - \frac{1}{1 + e^{-(\bar{f})^T w_j}} \right) w_{kj} \\ &= g_j(1 - g_j)w_{kj}\end{aligned}\tag{17}$$

역전파 (Back propagation)

Now,

$$\begin{aligned}\frac{\partial \bar{f}_k}{\partial v_{nk}} &= \frac{\partial f_k}{\partial v_{nk}} \\ &= \frac{\partial}{\partial v_{nk}} \left(\frac{1}{1 + e^{-(\bar{x})^T v_k}} \right) \\ &= \frac{-e^{-(\bar{x})^T v_k}}{1 + e^{-(\bar{x})^T v_k}} (-\bar{x}_n) \\ &= \frac{1}{1 + e^{-(\bar{x})^T v_k}} \left(1 - \frac{1}{1 + e^{-(\bar{x})^T v_k}} \right) \bar{x}_n \\ &= f_k(1 - f_k)\bar{x}_n\end{aligned}\tag{18}$$

역전파 (Back propagation)

Hence,

$$\frac{\partial E}{\partial v_{nk}} = \sum_{i=1}^I \sum_{j=1}^J \left\{ \left(g_j^{(i)} - y_j^{(i)} \right) \overbrace{g_j^{(i)} \left(1 - g_j^{(i)} \right)}^{\frac{\partial g_j}{\partial \bar{f}_k}} w_{kj} \underbrace{f_k^{(i)} \left(1 - f_k^{(i)} \right)}_{\frac{\partial \bar{f}_k}{\partial v_{nk}}} \bar{x}_n^{(i)} \right\} \quad (19)$$

Now, by considering all training examples,

$$v_{nk} \leftarrow v_{nk} - \alpha_2 \sum_{i=1}^I \sum_{j=1}^J \left\{ \left(g_j^{(i)} - y_j^{(i)} \right) g_j^{(i)} \left(1 - g_j^{(i)} \right) w_{kj} f_k^{(i)} \left(1 - f_k^{(i)} \right) \bar{x}_n^{(i)} \right\} \quad (20)$$

where $n = \{0, 1, \dots, N\}$ and $k = \{1, 2, \dots, K\}$.

역전파 (Back propagation)

- 역전파 요약

배치 경사 하강법을 통해 파라미터 $\theta = (v, w)$ 를 업데이트한다

$$w_{kj} \leftarrow w_{kj} - \alpha_1 \sum_{i=1}^I \left(g_j^{(i)} - y_j^{(i)} \right) g_j^{(i)} \left(1 - g_j^{(i)} \right) \bar{f}_k^{(i)}$$

where $k = \{0, 1, \dots, K\}$ and $j = \{1, 2, \dots, J\}$.

$$v_{nk} \leftarrow v_{nk} - \alpha_2 \sum_{i=1}^I \sum_{j=1}^J \left\{ \left(g_j^{(i)} - y_j^{(i)} \right) g_j^{(i)} \left(1 - g_j^{(i)} \right) w_{kj} f_k^{(i)} \left(1 - f_k^{(i)} \right) \bar{x}_n^{(i)} \right\}$$

where $n = \{0, 1, \dots, N\}$ and $k = \{1, 2, \dots, K\}$.

Pseudo code : MLP with 3 layers

- v, w 랜덤으로 초기화하기

for epoch = 1 to max_epoch {

$$FP : X \rightarrow \bar{X} \rightarrow \bar{\bar{X}} \rightarrow F \rightarrow \bar{F} \rightarrow \bar{\bar{F}} \rightarrow G \Rightarrow E$$

$$BP : \forall k, j \quad w_{kj} \leftarrow w_{kj} - \alpha_w \frac{\partial E}{\partial w_{kj}} \quad k = \{0, 1, \dots, K\} \quad j = \{1, 2, \dots, J\}$$

$$\forall n, k \quad v_{nk} \leftarrow v_{nk} - \alpha_v \frac{\partial E}{\partial v_{nk}} \quad n = \{0, 1, \dots, N\} \quad k = \{1, 2, \dots, K\}$$

}

Lab 3 : Multilayer Perceptron

- Tasks

1. data_lab3.txt의 데이터를 읽어서 x, y 를 반환하는 함수를 작성하여라.
data_lab3.txt는 x_1, x_2, y 의 3개의 열로 이루어진 데이터이다.
 2. MLP를 통한 분류기 모델을 구현하여라.
단 MLP는 3개의 층을 가지며, 은닉층은 5개의 뉴런으로 이루어져있다.
 3. 은닉층과 출력층의 파라미터 값 v, w 의 최적값은 무엇인가?
 4. 학습한 모델이 $(x_1, x_2) = (2, 2)$ 와 $(x_1, x_2) = (4, 4)$ 를 올바르게 분류하는지 검증하여라.
- +) iris.csv 데이터를 읽어서 $x_{train}, y_{train}, x_{test}, y_{test}$ 를 반환하는 함수를 작성하여라.
단, 함수 내에서 무작위로 순서를 섞은 뒤 7:3으로 train-test split을 하여라.
은닉층이 10개의 뉴런을 가지는 모델을 생성하고
100epoch마다 1번씩 train/test 데이터 각각의 error와 accuracy를 출력하여라.